

1 特異値分解 (SVD)

任意の実行列

$$A \in \mathbb{R}^{m \times n}$$

は

$$A = U \Sigma V^T$$

と分解できます。

1.1 1. 何をしているのか

ベクトル x に A を作用させる過程を

$$x \xrightarrow{V^T} V^T x \xrightarrow{\Sigma} \Sigma V^T x \xrightarrow{U} Ax$$

と見ます。

- V^T : 入力空間を右特異ベクトル基底へ回転・鏡映する
- Σ : 各直交方向を σ_i 倍する
- U : 出力空間の左特異ベクトル方向へ回転・鏡映する

つまり一般の線形写像を「直交変換 → 軸ごとの伸縮 → 直交変換」に分けています。

1.2 2. 特異値はどう求まるか

$$A^T A = V \Sigma^T \Sigma V^T$$

なので、 V の列は $A^T A$ の固有ベクトルです。また

$$\lambda_i(A^T A) = \sigma_i^2$$

です。

同様に U の列は $A A^T$ の固有ベクトルです。

したがって

$$Av_i = \sigma_i u_i$$

となります。右特異ベクトル方向 v_i の単位ベクトルを A が σ_i 倍し、左特異ベクトル方向 u_i へ送るという意味です。

1.3 3. ランクとの関係

非零特異値の個数がランクです。

$$\text{rank}(A) = \#\{i : \sigma_i > 0\}$$

零特異値に対応する右特異ベクトルは $\ker(A)$ を張ります。

1.4 4. 外積の和として見る

SVD は

$$A = \sum_{i=1}^r \sigma_i u_i v_i^\top$$

とも書けます。

各 $u_i v_i^\top$ はランク 1 行列です。したがって A は、重要度 σ_i を持つランク 1 成分の和として理解できます。

この見方から画像圧縮や低ランク近似が自然に出てきます。

1.5 5. 条件数との関係

full rank の場合

$$\kappa_2(A) = \frac{\sigma_{\max}}{\sigma_{\min}}$$

です。最小特異値が小さいとは、ある入力方向がほとんど潰されることを意味します。その方向を逆に復元しようとする誤差が大幅に増幅されます。

1.6 6. SVD が統一するもの

SVD から直接

- ランク
- 四つの基本部分空間
- 擬似逆行列
- 最小二乗
- 条件数
- 低ランク近似
- PCA
- 画像圧縮
- ノイズ除去

を説明できます。

SVD を単なる計算手法ではなく、**線形写像の幾何学的な標準形**として理解することが最重要です。