

1 PCA（主成分分析）

データ行列 $X \in \mathbb{R}^{n \times d}$ の各行をサンプルとし、まず各特徴量の平均を引いて中心化します。

$$X_c = X - \mathbf{1}\mu^\top$$

標本共分散行列は

$$C = \frac{1}{n-1} X_c^\top X_c$$

です。

1.1 PCA の目的

単位ベクトル v 方向へ射影した値は $X_c v$ です。その標本分散は

$$\frac{1}{n-1} \|X_c v\|_2^2 = \frac{1}{n-1} v^\top X_c^\top X_c v = v^\top C v$$

です。

したがって PCA は

$$\max_{\|v\|=1} v^\top C v$$

を解き、最も分散の大きい方向を探します。この解が C の最大固有値に対応する固有ベクトルです。

1.2 SVD との関係

$$X_c = U \Sigma V^\top$$

なら

$$C = \frac{1}{n-1} V \Sigma^2 V^\top$$

です。

したがって

- V の列 = 主成分方向
- $\sigma_i^2/(n-1)$ = 各主成分の標本分散

です。

上位 k 主成分への座標は

$$Z = X_c V_k$$

です。

1.3 深い見方

PCA は「分散最大化」と「再構成誤差最小化」という二つの見方を持ちます。上位主成分を残すことは、中心化データの最良 rank- k 近似を作ることと同値です。