

1 Chapter 09 — 低ランク構造・PCA・圧縮

この章では「高次元に見えるデータが、実は少数の方向でほとんど説明できる」という考えを扱います。

1.1 rank は自由度を測る

行列の rank が r なら、その列や行に含まれる独立方向は r 個だけです。

現実のデータは厳密には full rank でも、特異値が

$$100, 20, 5, 0.1, 0.01, \dots$$

のように急減することがあります。この場合「近似的には低ランク」と考えられます。

1.2 SVD が最良近似を与える

$$A_k = \sum_{i=1}^k \sigma_i u_i v_i^T$$

は $\text{rank} \leq k$ の中で最良の近似です。

つまり「上位特異値を残す」は便利な経験則ではなく、明確な最適性定理を持っています。

1.3 PCA は何をしているのか

中心化データに対して PCA は

- 射影後の分散を最大にする方向を探す
- 再構成誤差を最小にする低次元部分空間を探す

という二つの等価な問題です。

SVD によってこの二つが一つにつながります。

1.4 圧縮とノイズ除去

どちらも小さい特異成分を捨てますが、意味は異なります。

- 圧縮: 少数パラメータで近似する
- denoising: 小さい成分を主にノイズと仮定する

後者にはモデル仮定があり、弱い信号まで消す危険があります。

1.5 到達基準

「次元削減とは単に列数を減らすことなく、データの主要部分空間を見つけること」と説明できることを目標にします。